

Analyse de graphes IMDb

Graphes et Open Data



Construction d'un réseau de collaborations entre acteurs · Détection de communautés · Visualisation web interactive

Zaineb BENMAHMOUD

2025/2026

Python · NetworkX · Streamlit · Pandas · Faolium · Plotly

Contexte & Objectifs

Contexte


Exploration des collaborations cinématographiques à partir des données ouvertes IMDb.

- Projet Graphes et Open Data
- Source : données IMDb publiques (Internet Movie Database)
- Objectif : transformer des fichiers bruts en graphes analytiques

Idée générale

Construire un réseau de collaborations entre acteurs, puis l'analyser avec des outils de théorie des graphes.

- Visualiser les collaborations entre acteurs
- Détecter des communautés de collaboration
- Explorer les gens dominants dans le réseau



Données & Méthodologie

5 fichiers TSV open data fusionnés progressivement

title.principals.tsv

Rôles principaux par titre — lien acteurs ↔ films

name.basics.tsv

Identités des personnes — noms, métiers, années

title.basics.tsv


Métadonnées des titres — genre, année, type

title.ratings.tsv

Notes et votes — popularité des œuvres

title.akas.tsv

Titres alternatifs — internationalisation



~31 000

Acteurs

215

Communautés détectées

563 847


Liens acteur-acteur

300 000

Lignes source traitées

Question Centrale

Comment un graphe d'acteurs permet-il de révéler les communautés, les liens et les distances du réseau ?



Une représentation de réseau permet de voir à la fois les collaborations directes, les communautés d'acteurs et les chemins qui relient les différentes parties du graphe.

Modélisation et Logique de Calcul

Pour répondre à cette problématique, le projet s'appuie sur :

01 — Détection des communautés

Algorithme de Louvain basé sur la modularité

02 — Graphe acteur ↔ acteur

Chaque sommet = 1 acteur, chaque arête = un film en commun

03 — Analyse du poids des liens

Poids = nombre de films partagés entre deux acteurs

04 — Calcul des plus courts chemins

Distance = 1 / poids ; algorithme de Dijkstra

- 1 sommet = 1 acteur unique (identifié par nconst)
- 1 arête = au moins 1 film en commun entre deux acteurs
- Poids = nombre de films partagés (plus le poids est élevé, plus la collaboration est forte)

$$Q = \frac{1}{2m} \sum_{ij} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j),$$

- Graphe non orienté et pondéré
- Détection de communautés par modularité (algorithme de Louvain)
- Plus court chemin avec distance = 1 / poids(algorithme de Dijkstra)

05 — Lecture globale du réseau à plusieurs niveaux — Vue globale, bulles de communautés, graphes secondaires (films, créateurs)



Fonctionnalités Principales du Site

- Recherche par acteur ou film avec filtres interactifs
- Visualisation du graphe principal avec clic sur sommets et arêtes
- Affichage coloré des communautés détectées automatiquement
- Calcul et affichage du plus court chemin entre deux acteurs
- Vue globale, bulles de communautés, graphes secondaires
- Synthèse et statistiques du projet

Indicateurs principaux du graphe

31 030

acteurs source

dans la base IMDb filtrée

30 926

acteurs reliés

dans le graphe construit

563 847

liens acteur-acteur

arêtes dans le graphe principal

215

communautés détectées

par l'algorithme de Louvain

Ces résultats montrent que le réseau construit est suffisamment riche pour révéler des structures de collaboration à grande échelle.

IMDb map Communautés

Méthode de travail

IMDb map Communautés

IMDb map Communautés

Nouvel onglet

localhost:8501/?view=Synthese+projet

En pause

Deploy

Graphes interactifs acteurs

Carte acteurs

Analyses

Exemples reseau

Synthese projet

Donnees et details

Filtres de donnees

Titres geolocalises

11,203

Acteurs dans le graphe

2,046

Communautes

0

Titres disponibles

500

Synthese du projet et reponses aux questions

Cette vue utilise les exports globaux prepares sur le backend large (cache 300000 lignes). Independamment des filtres interactifs du haut.

Acteurs source

31,030

Acteurs relies

30,926

Liens acteur-acteur

563,847

Communautes detectees

215

Grandes communautes detaillees

18

Acteurs dans 'Autres'

1,290

Acteurs non relies / retires

104

Lignes sources backend

300,000

1. Deux vues globales pour expliquer le backend

Vue globale des ~31 000 acteurs du backend IMDb

Les grandes communautes sont separees : les petites sont regroupees dans un ensemble 'Autres communautes'.

Communaute 122

2450 acteurs

Genre: Drama, Comedie, Romance

Communaute 122

1200 acteurs

Genre: Drama, Comedie, Thriller

Communaute 48

4500 acteurs

Genre: Drama, Thriller, Comedie

Communaute 11

5000 acteurs

Genre: Drama, Comedie, Thriller

Communaute 14

1000 acteurs

Genre: Comedie, Thriller, Science-fiction

Communaute 136

1000 acteurs

Genre: Romance, Drama, Comedie

Communaute 49

1000 acteurs

Genre: Drama

Communautes / legend

Communaute 122

Communaute 48

Communaute 122

Communaute 122

Communaute 122

Communaute 122

Communaute 122

Communaute 122

Communaute 122

Communaute 122

Ce que montre cette image

- Tous les points representent des acteurs.
- Cette vue utilise environ 30,926 acteurs relies sur une base source de 31,030 acteurs.
- Les 18 plus grandes communautes sont separees visuellement.
- Les petites communautes restantes sont regroupees dans une zone **Autres communautes**.
- Les bulles sont placees d'abord selon leurs relations entre communautes, puis espacees artificiellement pour eviter qu'elles se chevauchent.

Comment les communautes sont faites

8

Limites et Perspectives

Limites actuelles

- Géolocalisation des personnes imprécise
- Affichage complet limité par les performances

Perspectives d'amélioration

- Source externe pour les budgets de films
- Comparaison d'algorithmes de communautés

Conclusion

Résultats clés :

Mise en évidence des
collaborations entre acteurs

Détection de communautés et
calcul de chemins

Création d'un site interactif pour
explorer les résultats

L'application web interactive rend ces analyses accessibles, explorables et interprétables par tout utilisateur.

Merci !
Questions ?